ЛР4: Булев поиск

Задание

Нужно реализовать ввод поисковых запросов и их выполнение над индексом, получение поисковой выдачи.

Синтаксис поисковых запросов:

- Пробел или два амперсанда, «&&», соответствуют логической операции «И».
- Две вертикальных «палочки», «||» – логическая операция «ИЛИ»
- Восклицательный знак, «!» – логическая операция «НЕТ»
- Могут использоваться скобки.

Парсер поисковых запросов должен быть устойчив к переменному числу пробелов, максимально толерантен к введённому поисковому запросу. Примеры запросов:

- [московский авиационный институт]
- [(красный || желтый) автомобиль]
- [руки !ноги]

Должна быть реализована утилита командной строки, загружающая индекс и выполняющая поиск по нему для каждого запроса на отдельной строчке входного файла. В отчёте должно быть отмечено:

- Скорость выполнения поисковых запросов.
- Примеры сложных поисковых запросов, вызывающих длительную работу.
- Каким образом тестировалась корректность поисковой выдачи.

Метод решения

1. Реализация поиска по индексам
2. Реализация операций && и ||
3. Реализация парсера поисковых запросов
4. Сбор статистики, тестирование, оценка результатов

Журнал выполнения

№	Действие	Проблема	Решение
1	Тестирование поиска	Неправильно строится индекс	Отладка индексатора

Реализация

- Поиск по индексам реализован итерационным, т.е. за одну итерацию происходит поиск по одному индексу. После всех итераций результаты поиска для каждого индекса объединяются в один результирующий список. В память одновременно загружается только один индекс, таким образом мы соблюдаем ограничение по использованию RAM.

- Реализация операции && состоит в поиске совпадений между двумя списками. Для решения данной задачи отлично подходят множества. Совпадение между списками результатов

поиска - есть ни что иное как пересечение двух множеств. Язык c++ обладает возможностью использовать реализацию абстрации множества с операциями пересечения.

- Реализация операции || , главным образом, состоит в объединении двух множеств.
- Релизация парсера поисковых запросов выполняется с помощью алгоритма сортировочной станции. Перед реализацией алгоритма перевода инфиксной записии выражений в постфиксную необходимо предобработать исходные запросы: понизить капиталиацзию, учесть пробелы, убрать лишние знаки.

Результаты выполнения

Корректность результатов тестировалась вручную.

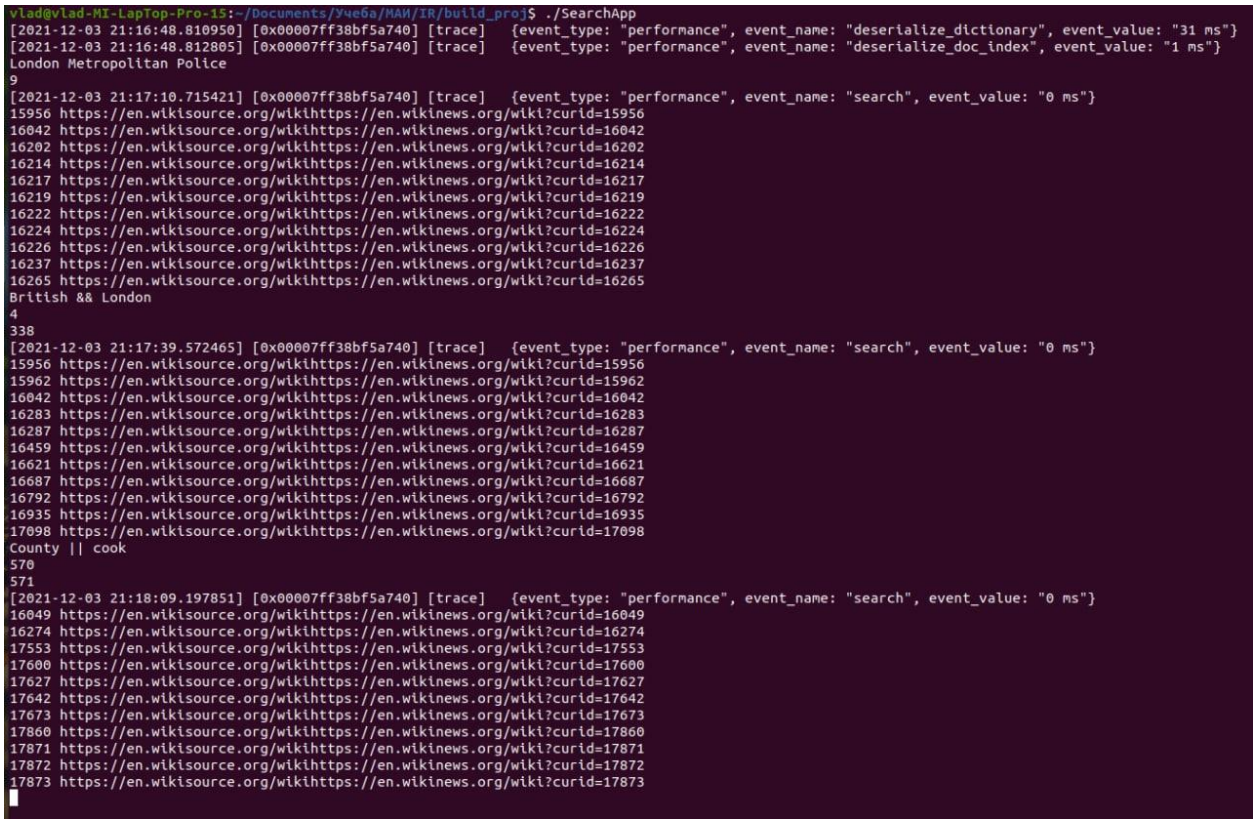

Исходный код

```
#include "../bsbi/inv_index_provider.h"
#include "../boolean_queries/expression_tree.h"
#include "../boolean_queries/parser.h"
#include "../boolean_queries/tokenization.h"
#include "../tokenization/word_tokenizer.h"

namespace search_engine {

class SearchEngine {
public:
    explicit SearchEngine(std::shared_ptr<bsbi::InvIndexProvider>);
    std::vector<uint64_t> search(const std::string& query);
private:
    std::shared_ptr<bsbi::InvIndexProvider> invIndexProvider_;
    std::shared_ptr<tokenization::WordTokenizer> wordTokenizer_;
};

} // namespace search_engine
```

```
#include "search_engine.h"

#include "../common/handler.h"

namespace search_engine {

SearchEngine::SearchEngine(std::shared_ptr<bsbi::InvIndexProvider> invIndexProvider)
    : invIndexProvider_(std::move(invIndexProvider))
    , wordTokenizer_(std::make_shared<tokenization::SimpleWordTokenizer>())
{}

std::vector<uint64_t> SearchEngine::search(const std::string& query)
{
    common::PerformanceHandler handler("search");
    auto tokenizedExpression = boolean_queries::tokenizeExpression(query, *wordTokenizer_);
    auto rpnExpression = boolean_queries::reversePolishNotation(tokenizedExpression);
    auto expressionTree = boolean_queries::ExpressionTree(rpnExpression);
    return expressionTree.evaluate(*invIndexProvider_);
}
```

```cpp
int main() {
    auto invIndexProvider = bsbi::createInvIndexProvider("./OUTPUT");
    auto documentIndex = document::createDocumentIndex("./OUTPUT/document_index.bin");

    search_engine::SearchEngine searchEngine(invIndexProvider);

    std::string query;
    while (std::getline(std::cin, query, '\n')) {
        int resultsPrinted = 0;
        for(const auto& docId: searchEngine.search(query)) {
            std::cout << docId << ' ' << URL_PREFIX + documentIndex->url(docId) << '\n';
            resultsPrinted += 1;
            if (resultsPrinted > 10) {
                break;
            }
        }
    }
}
```

Выводы

В процессе выполнения данной лабораторной работы был реализован и протестирован булев поиск. В целом было интересно реализовывать поиск над статьями википедии. По результатам ЛР сразу видны отличия данной реализации от эталонных поисковых систем: скорость, ранжирование, интерфейс.